C:\PROYECTOS**DATATUTOR>_**

DataTutor



Un tutor RAG que responde solo con lo que puede sustentar

LangChain · LangGraph · modelo local · pgvector

Michelle Ruiz Segura · Juan José Ramírez Pulgarín · Isaac Camilo Giraldo Gómez

Integración e Implementación de Software · Octubre 2026

El problema

673

Libros enormes

Un solo libro de bases de datos tiene tiene 673 páginas. Encontrar un concepto toma tiempo.

?!

IA que inventa

Los asistentes generales responden con seguridad aunque no sepan.

[ ]

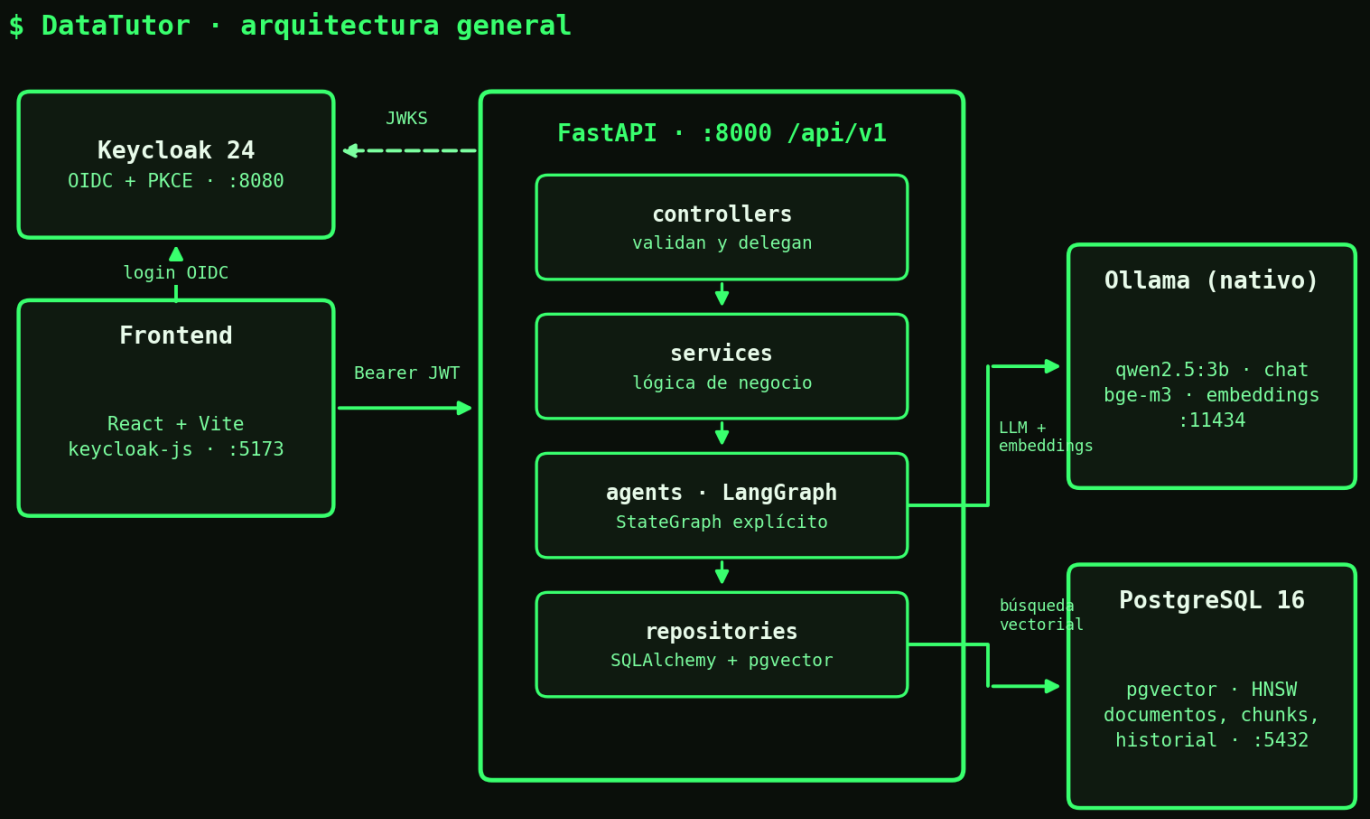
Sin fuentes

No indican de qué documento ni página página sale cada respuesta.

Necesidad: un tutor verificable que cite documento y página, y que diga «no sé» cuando no hay sustento.

Arquitectura

Solo la API habla con el modelo y la base de datos. Todo corre en el portátil: la demo funciona sin internet.



Tecnologías usadas

Agente
LangChain · LangGraph · RAG

Modelo local
Ollama · qwen2.5:3b · bge-m3

Datos
PostgreSQL 16 · pgvector (HNSW)

Backend
Python 3.12 · FastAPI · SQLAlchemy

Frontend
React 19 · Vite · keycloak-js

Seguridad
Keycloak 24 · JWT RS256 · PKCE

Todo gratuito, sin GPU y con el flujo del agente escrito en código (nada de herramientas visuales).

Agente: LangChain + LangGraph

LangChain conecta el modelo local · LangGraph decide el camino de cada pregunta



rewrite_query
Zona gris: reescribe la consulta una sola vez.
vez.

clarify
Pregunta de 4 palabras o menos: pide precisar.

refuse
Sin evidencia: mensaje fijo de rechazo.

5 defensas contra alucinaciones: umbral de similitud · juez de suficiencia · prompt restrictivo · rechazo explícito · fuentes visibles
visibles

Base vectorial y carga de documentos

1
Subir PDF

2
Validar
30 MB · hash

3
Extraer
PyMuPDF

4
Fragmentar
1000 / 200

5
Embeddings
bge-m3

6
Guardar
pgvector

1024
dimensiones por vector

HNSW
índice coseno · puntaje = 1 − distancia

6
documentos indexados (≈ 7 400 fragmentos)
fragmentos)

Estados del documento: **pending → processing → ready / failed**

Seguridad y usuarios

Login con Keycloak
OIDC + PKCE; el backend nunca ve contraseñas.

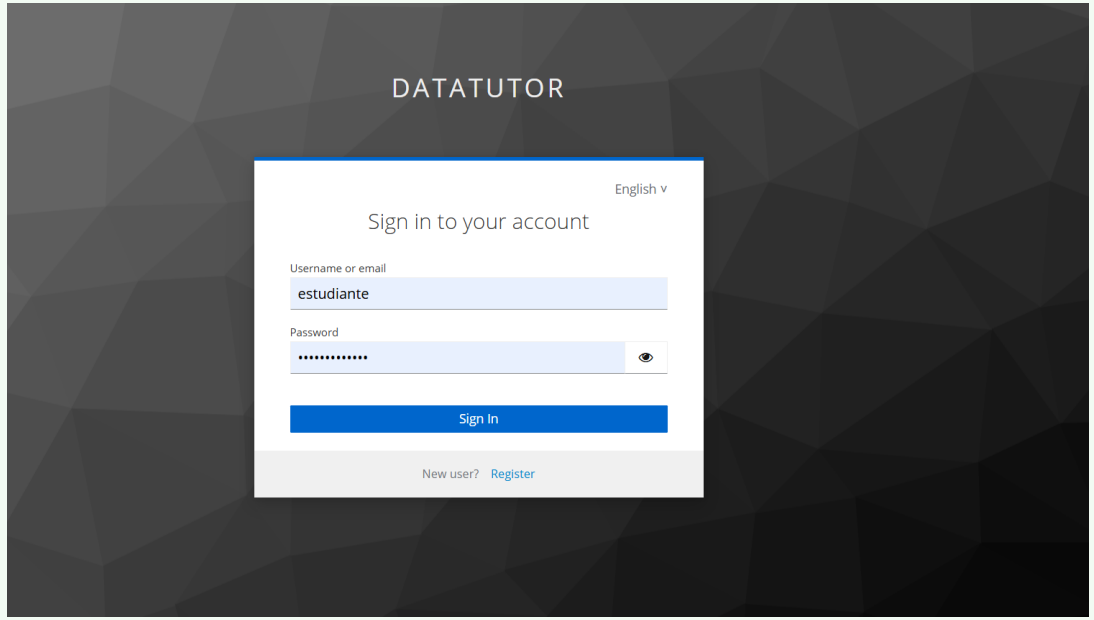
API protegida con JWT
Valida firma RS256, emisor, audiencia y vigencia. Solo /health es pública.

Cada usuario ve lo suyo
Filtro por owner_id en cada consulta; un recurso ajeno responde 404.

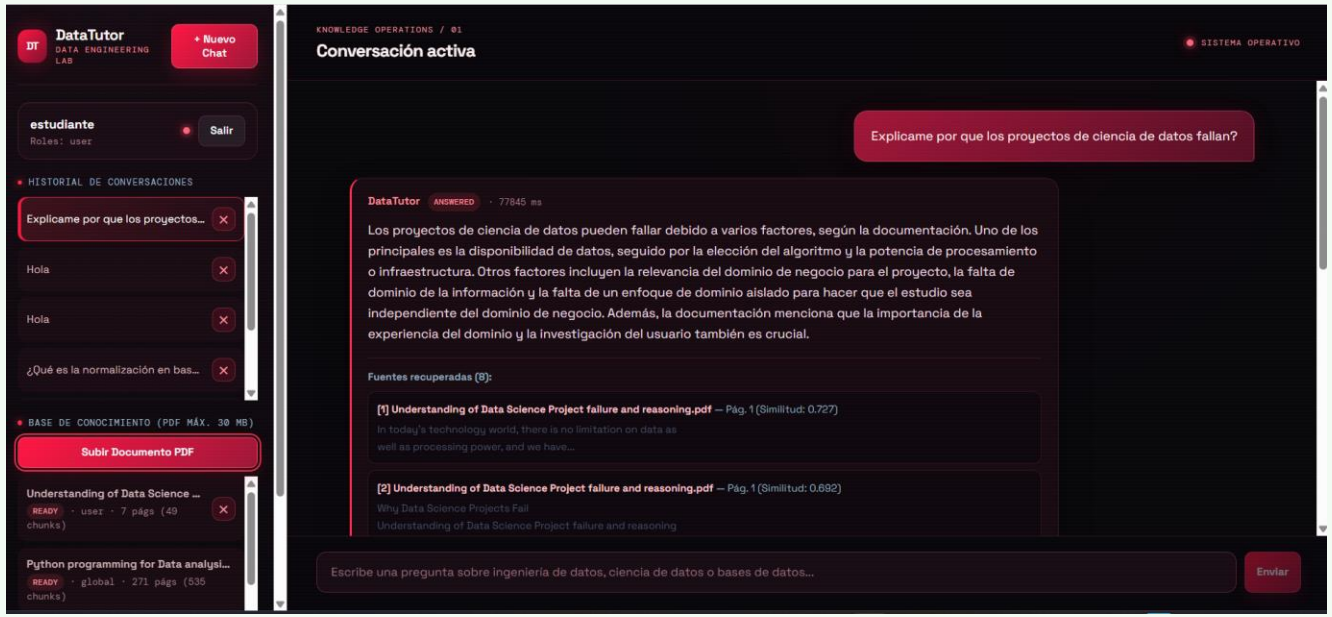
Subidas y secretos cuidados
Tamaño, tipo y hash validados; credenciales solo en .env.



Demostración

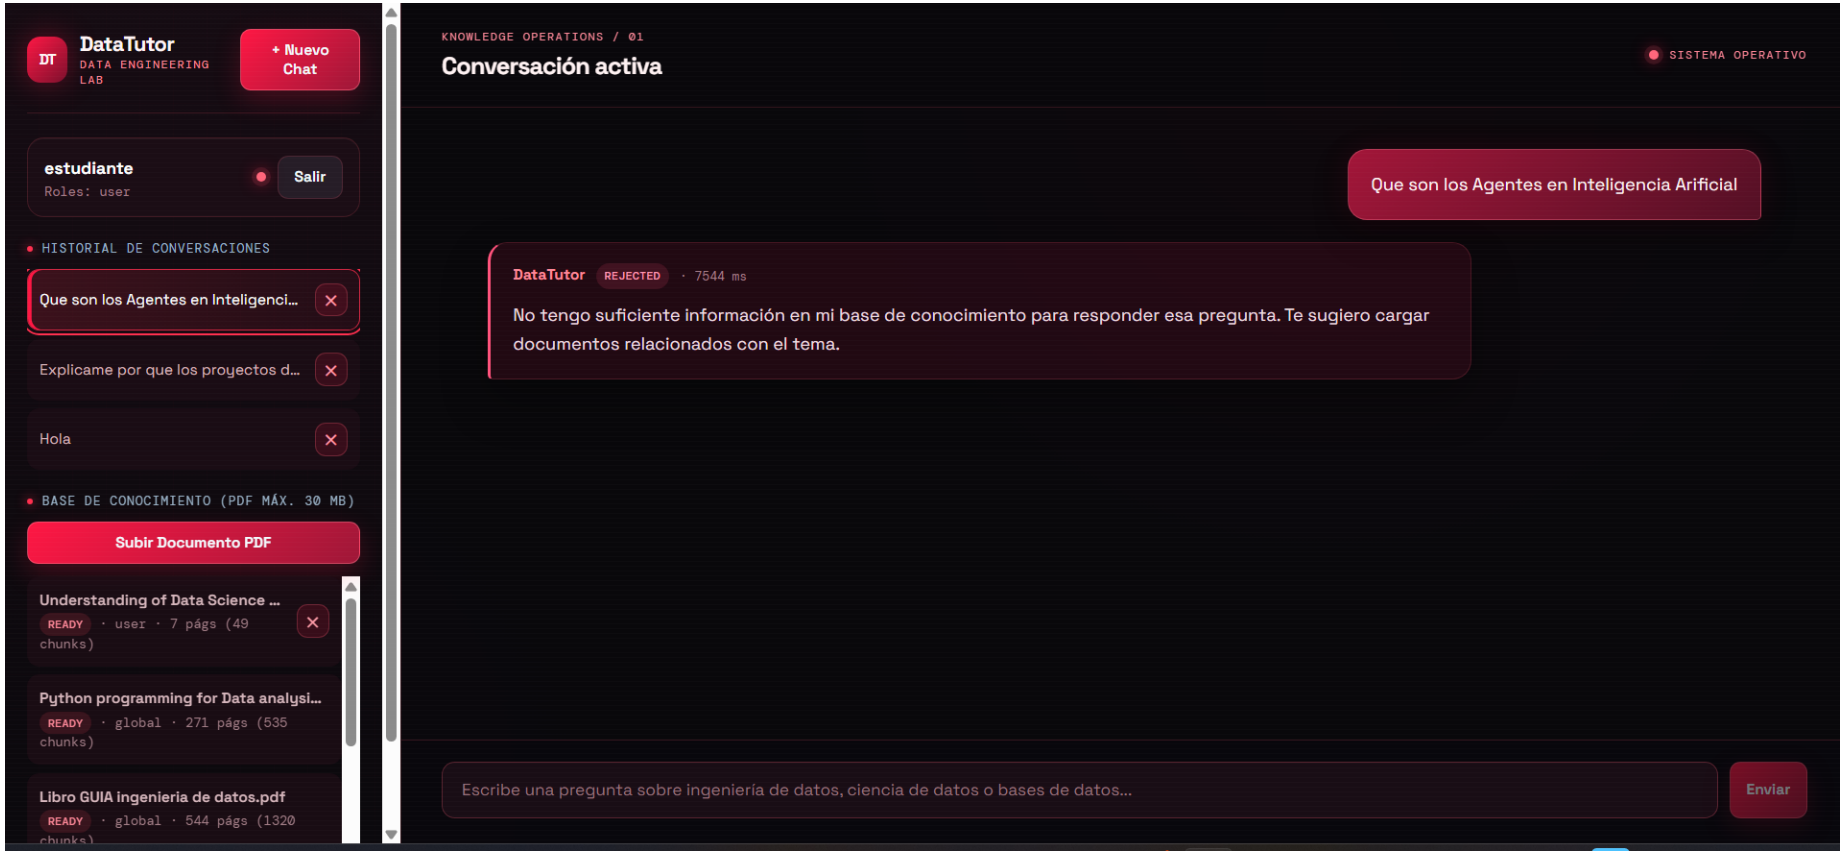


1 · Login



2 · Respuesta con fuentes

Demostración



3 · Rechazo sin información

Conclusiones

01

Un modelo pequeño basta si el grafo lo respalda: el valor está en el diseño, no en el tamaño.

02

DataTutor responde con fuentes o dice «no sé»: no inventa.

03

Por mejorar: latencia (12–33 s en CPU), citas en línea y calibración de umbrales.